

Predykcja skali przestępczości


Spis treści

1. Cel badania i opis zbioru danych
2. Metodologia i rozwiązanie
3. Wstępne przetwarzanie danych
4. Metoda oceniania jakości modelu.
5. Wyniki eksperymentalne
6. Podsumowanie: własne komentarze, wnioski.

1. Cel badania i opis zbioru danych

Celem projektu jest opracowanie modelu regresyjnego zdolnego do przewidywania skali przestępczości (ViolentCrimesPerPop) w regionach miejskich USA na podstawie wskaźników socjoekonomicznych i demograficznych.

- Liczba rekordów: 1994.
- Liczba atrybutów: Pierwotnie ponad 120 cech; po selekcji i czyszczeniu do modelu wykorzystano 21 kluczowych zmiennych (m.in. dochód, struktura wieku, wykształcenie, warunki mieszkaniowe).
- Zmienna celu: Wartość ciągła z zakresu $[0,1]$, reprezentująca znormalizowaną liczbę przestępstw.



2. Metodologia i rozwiązanie

W badaniu porównano skuteczność czterech podejść regresyjnych:

- **Modele Liniowe:** Klasyczna regresja oraz model z regularyzacją (Lasso i Ridge).
- **Regresja Nieliniowa:** Model wielomianowy drugiego i trzeciego stopnia, badający nieliniowe zależności w danych demograficznych.
- **Las Losowy (Random Forest):** Algorytm zespołowy poddany optymalizacji hiperparametrów przez GridSearchCV w celu znalezienia najlepszej struktury drzew.
- **Sieci Neuronowe (MLP):** Model głęboki zbudowany w środowisku Keras/TensorFlow z warstwami Dropout, zapobiegającymi przeuczeniu.

3. Wstępne przetwarzanie danych

- 1) **Filtracja braków:** Usunięto 24 atrybuty posiadające powyżej 50% brakujących wartości.
- 2) **Selekcja:** Ręcznie wybrano 25 kluczowych zmiennych socjoekonomicznych.
- 3) **Analiza korelacji:** Skonstruowano macierz korelacji, na podstawie której odrzucono cechy nadmiarowe o bardzo wysokiej współzależności (np. usunięto jeden z parametrów dotyczących wieku), co dało finalnie 23 atrybuty.

4. Metoda oceniania jakości modelu.


Dane podzielono na zbiór treningowy (75%) i testowy (25%). Jakość oceniono za pomocą metryk: R2, MAE, MSE oraz RMSE.

5. Wyniki eksperymentalne


Porównanie skuteczności modeli regresyjnych według poniższych metryk

Model	Linear	Lasso	Ridge	Polynomial ^2	Polynomial ^3	Random forest	Neural network
MSE	0.0168	0.0292	0.0168	0.0227	1.4932	0.0174	0.0174
RMSE	0.1296	0.1709	0.1296	0.1506	1.2220	0.1320	0.1319
MAE	0.0912	0.1330	0.0912	0.1050	0.5822	0.0936	0.0950
R2	0.6545	0.3990	0.6545	0.5335	-29.7095	0.6416	0.6422

Wykres wartości rzeczywistych względem przewidywanych i wykres reszt w funkcji wartości przewidywanych dla regresji liniowej:



Wykres wartości rzeczywistych względem przewidywanych i wykres reszt w funkcji wartości przewidywanych dla regresji wielomianowej:



6. Podsumowanie: własne komentarze, wnioski.

Regresja liniowa

Regresja liniowa osiągnęła najlepsze wyniki spośród testowanych modeli, uzyskując najniższe wartości błędów MSE, RMSE oraz MAE, a także najwyższy współczynnik determinacji R^2 . Wyniki te wskazują, że po odpowiednim wstępnym przetwarzaniu danych relacja pomiędzy wybranymi cechami a zmienną docelową może być w dużej mierze aproksymowana zależnością liniową.

Analiza wykresu wartości rzeczywistych względem wartości przewidywanych potwierdza poprawne odwzorowanie ogólnego trendu w danych, szczególnie dla niskich i średnich wartości zmiennej docelowej. Jednocześnie widoczny jest wzrost rozrzutu predykcji dla wyższych wartości, co sugeruje ograniczoną zdolność modelu do precyzyjnego odwzorowania obserwacji skrajnych.

Regresja Lasso

Regresja Lasso wypadła wyraźnie gorzej w porównaniu do innych modeli. Uzyskane wartości błędów były wyższe, a współczynnik R^2 znacząco niższy. Może to wskazywać, że regularyzacja L1 usunęła lub nadmiernie osłabiła cechy istotne dla predykcji, co doprowadziło do pogorszenia jakości modelu.

Regresja Ridge

Model Ridge osiągnął identyczne wyniki jak regresja liniowa dla wszystkich metryk. Oznacza to, że zastosowanie regularyzacji L2 nie wpłynęło istotnie na jakość predykcji, co może świadczyć o braku silnej wielokolinearności w finalnym zbiorze cech lub o dobrze dobranym etapie selekcji zmiennych.

Regresja wielomianowa drugiego stopnia

Model wielomianowy drugiego stopnia osiągnął wyniki lepsze niż Lasso, ale gorsze od modeli liniowych. Choć pozwala on modelować nieliniowe zależności, w tym przypadku wprowadzenie dodatkowej złożoności nie przyniosło poprawy, lecz doprowadziło do wzrostu błędów.

Regresja wielomianowa trzeciego stopnia

Regresja wielomianowa trzeciego stopnia okazała się najsłabszym modelem w całym badaniu. Bardzo wysokie wartości MSE i RMSE oraz skrajnie niski, ujemny współczynnik determinacji R^2 jednoznacznie wskazują na silne przeuczenie modelu oraz całkowity brak zdolności generalizacji na zbiorze testowym.

Wnioski te znajdują bezpośrednie potwierdzenie w analizie wykresów diagnostycznych. Wykres wartości rzeczywistych względem wartości przewidywanych ujawnia znaczne rozbieżności pomiędzy predykcjami a obserwacjami rzeczywistymi, w tym występowanie ekstremalnych wartości predykcji znacząco wykraczających poza zakres zmiennej docelowej. Świadczy to o niestabilności modelu oraz nadmiernej wrażliwości na niewielkie zmiany danych wejściowych.

Szczególnie istotnym sygnałem przeuczenia jest wykres reszt w funkcji wartości przewidywanych, na którym widoczna jest silna, niemal liniowa zależność pomiędzy resztami a predykcjami. Oznacza to, że błędy modelu nie mają charakteru losowego, lecz są bezpośrednio powiązane z jego własnymi predykcjami, co stanowi poważne naruszenie założeń modelu regresyjnego. W rezultacie, mimo pozornie lepszego dopasowania lokalnego, model ten nie nadaje się do wiarygodnych predykcji ani interpretacji.

Random Forest

Random Forest osiągnął bardzo dobre wyniki, zbliżone do modeli liniowych. Uzyskane wartości błędów były niskie, a R^2 wskazuje na dobrą zdolność wyjaśniania zmienności zmiennej docelowej. Jednak nie przewyższył prostszej regresji liniowej.

Sieć neuronowa

Sieć neuronowa osiągnęła wyniki porównywalne z Random Forest, uzyskując niskie wartości MSE i RMSE oraz $R^2 = 0.6422$. Pomimo swojej wyższej złożoności nie przewyższyła najlepszego modelu liniowego, co sugeruje, że w tym zadaniu większa złożoność modelu nie przekłada się na lepszą jakość predykcji. Wyniki uzyskiwane przez sieć neuronową nie były identyczne przy każdym uruchomieniu modelu. Wartość współczynnika R^2 ulegała niewielkim wahaniom, mieszcząc się w przedziale 0.63–0.66.

Wnioski końcowe

- Najlepszym modelem okazała się regresja liniowa (oraz Ridge).
- Modele zbyt złożone (wielomianowe wysokiego stopnia) prowadzą do przeuczenia.
- Random Forest i sieć neuronowa oferują dobrą jakość predykcji, lecz nie przewyższają prostszych metod.
- Odpowiednie przygotowanie danych ma kluczowe znaczenie i może sprawić, że prosty model będzie skuteczniejszy niż zaawansowane algorytmy.